Arya Mahardika

Peneliti Machine Learning · NLP Bahasa Indonesia

arya.mahardika@email.com · +62 812 5553 8146 · Jakarta, Indonesia · aryamahardika.ai
github.com/aryamahardika · ORCID 0000-0003-5552-7719

KEAHLIAN

Riset
Pemodelan bahasa, Terjemahan mesin, Pengenalan ucapan, Evaluasi

Rekayasa
Distilasi, Pipeline data, MLOps

Perangkat
Python, PyTorch, JAX, Hugging Face, Kubernetes

PENGHARGAAN

Makalah Terbaik — 2025
Conference on Low-Resource Language Technology

Hibah Peneliti Muda — 2024
Yayasan Riset Bahasa Nusantara · Rp600 juta

Beasiswa Magister — 2016
LPDP

BAHASA

Bahasa Indonesia
Bahasa ibu

Bahasa Bali
Bahasa ibu

Bahasa Inggris
Fasih (IELTS 7,5)

Bahasa Jawa
Percakapan

Ringkasan

Applied scientist yang membangun model bahasa untuk bahasa-bahasa daerah Indonesia, bukan hanya bahasa Indonesia. Sembilan tahun berkiprah di riset dan produksi NLP, dari terjemahan mesin sumber daya rendah hingga pengenalan ucapan bahasa Jawa dan Sunda. Model saya melayani 4 juta permintaan per hari, dan dataset terbuka saya dipakai lebih dari 30 kelompok riset.

Pengalaman

Lentera Nalar AI Lab — Jakarta
Senior Research Scientist, NLP — Jan 2023 – Sekarang

- Memimpin tim lima orang melatih model 7 miliar parameter untuk bahasa Indonesia dan 12 bahasa daerah; unggul 9 poin dari model terbuka di benchmark kami.
- Merilis NusaEval, benchmark 40 tugas yang kini dipakai lebih dari 30 kampus dan lab.

Suarakata — Bandung
Applied Scientist, Speech — Mar 2020 – Des 2022

- Membangun pengenalan ucapan bahasa Jawa dan Sunda untuk produk call center; word error rate turun dari 31% ke 14%.
- Merancang pipeline yang menghimpun 6.000 jam rekaman suara dari 1.900 penutur relawan berbayar.

Institut Teknologi Bandung — Bandung
Asisten Peneliti, Linguistik Komputasional — Sep 2017 – Feb 2020

- Menyusun korpus paralel Indonesia–Jawa berisi 2 juta kalimat yang dirilis dengan lisensi terbuka.

Publikasi

NusaEval: a benchmark for language models in Indonesian and twelve regional languages — 2025
Conference on Low-Resource Language Technology 2025
Penulis utama, bersama S. Hutapea, N. Rahim dan M. Tan

Cheap tokens, fair models: vocabulary design for Austronesian languages — 2024
Journal of Computational Linguistics in Asia 8(1)

Crowd-sourced speech corpora for Javanese and Sundanese ASR — 2022
Workshop on Speech for Under-Resourced Languages

Pendidikan

University of Edinburgh — Master of Science · Predikat distinction
Artificial Intelligence — Edinburgh, Inggris · 2016 – 2017

Institut Teknologi Bandung — Sarjana Teknik (S.T.) · IPK 3,71
Teknik Informatika — Bandung · 2011 – 2015